INSTITUTO FEDERAL
Goiás

MLP para classificar a evolução de casos de SRAG

Cura ou óbito?

Juliano Costa e Victor Hugo Jesus

Deep Learning · Frente 3.1: Multilayer Perceptron

Agenda

INSTITUTO FEDERAL
Goiás

- O problema
- Os dados
- Análise exploratória
- Pré-processamento e modelo
- Experimentos
- Resultados no teste
- Limitações e conclusões

O problema

INSTITUTO FEDERAL
Goiás

- Base: SIVEP-Gripe (SRAG), Ministério da Saúde
- Cada linha: um caso de SRAG internado
- Alvo: **cura (0)** ou **óbito (1)**
- Classificação binária, com mais curas do que óbitos
- Pergunta: com o que se sabe na internação, qual o risco de óbito?

Os dados: divisão por ano

INSTITUTO FEDERAL
Goiás

Conjunto	Anos	Casos	Óbitos
Treino	2020 e 2021	2.512.120	28,2%
Validação	2022	470.059	18,2%
Teste	2023	241.411	9,5%

- Treinamos no passado e testamos no futuro
- O teste só foi usado no final

Quais variáveis usamos

INSTITUTO FEDERAL
Goiás

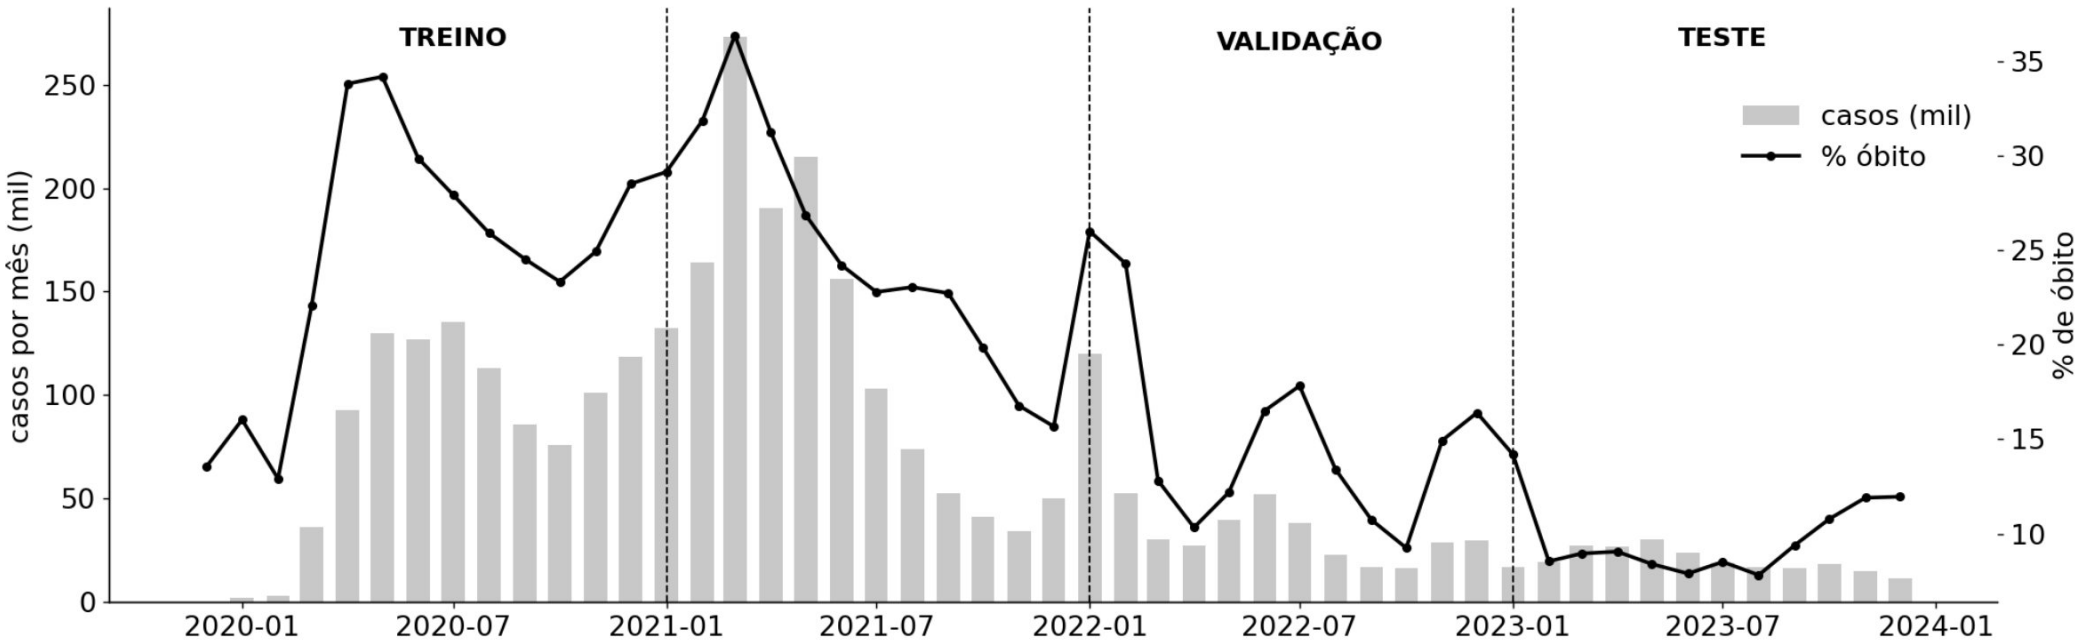
Usamos

- Idade, sexo, raça, escolaridade, UF
- Sintomas (falta de ar, saturação baixa…)
- Doenças prévias (diabetes, coração…)
- Vacinação
- Dias entre o 1º sintoma e a internação

Não usamos

- UTI e ventilação (acontecem depois)
- Data do desfecho e classificação final (entregam a resposta)
- Datas e município (não servem para outros anos)

A taxa de óbito caiu com o tempo



- De cerca de 30% (2020–2021) para cerca de 10% (2023)

Em 2023, a maioria dos casos são crianças

Ano	Idade mediana	Menores de 18 anos	Óbitos
2020	61 anos	7%	28%
2021	56 anos	9%	28%
2022	58 anos	31%	18%
2023	7 anos	57%	10%

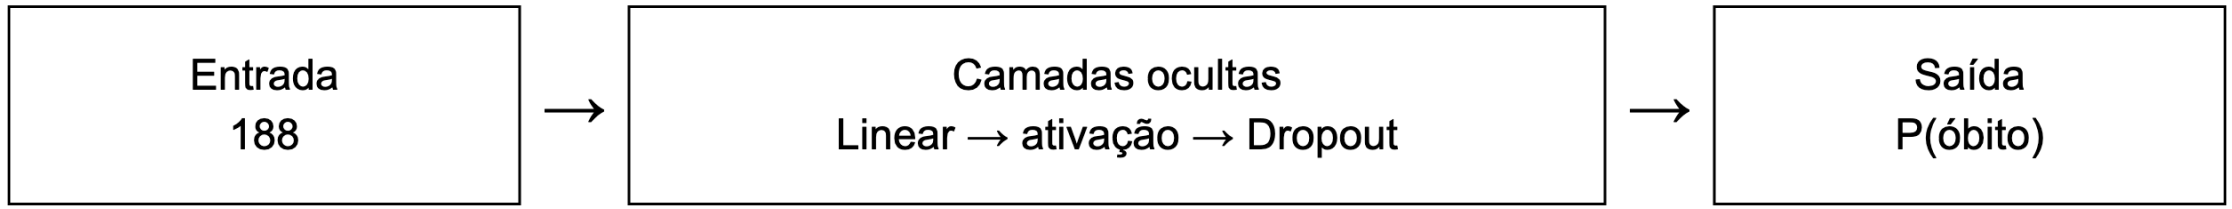
- O teste é uma população diferente da do treino

Pré-processamento

INSTITUTO FEDERAL
Goiás

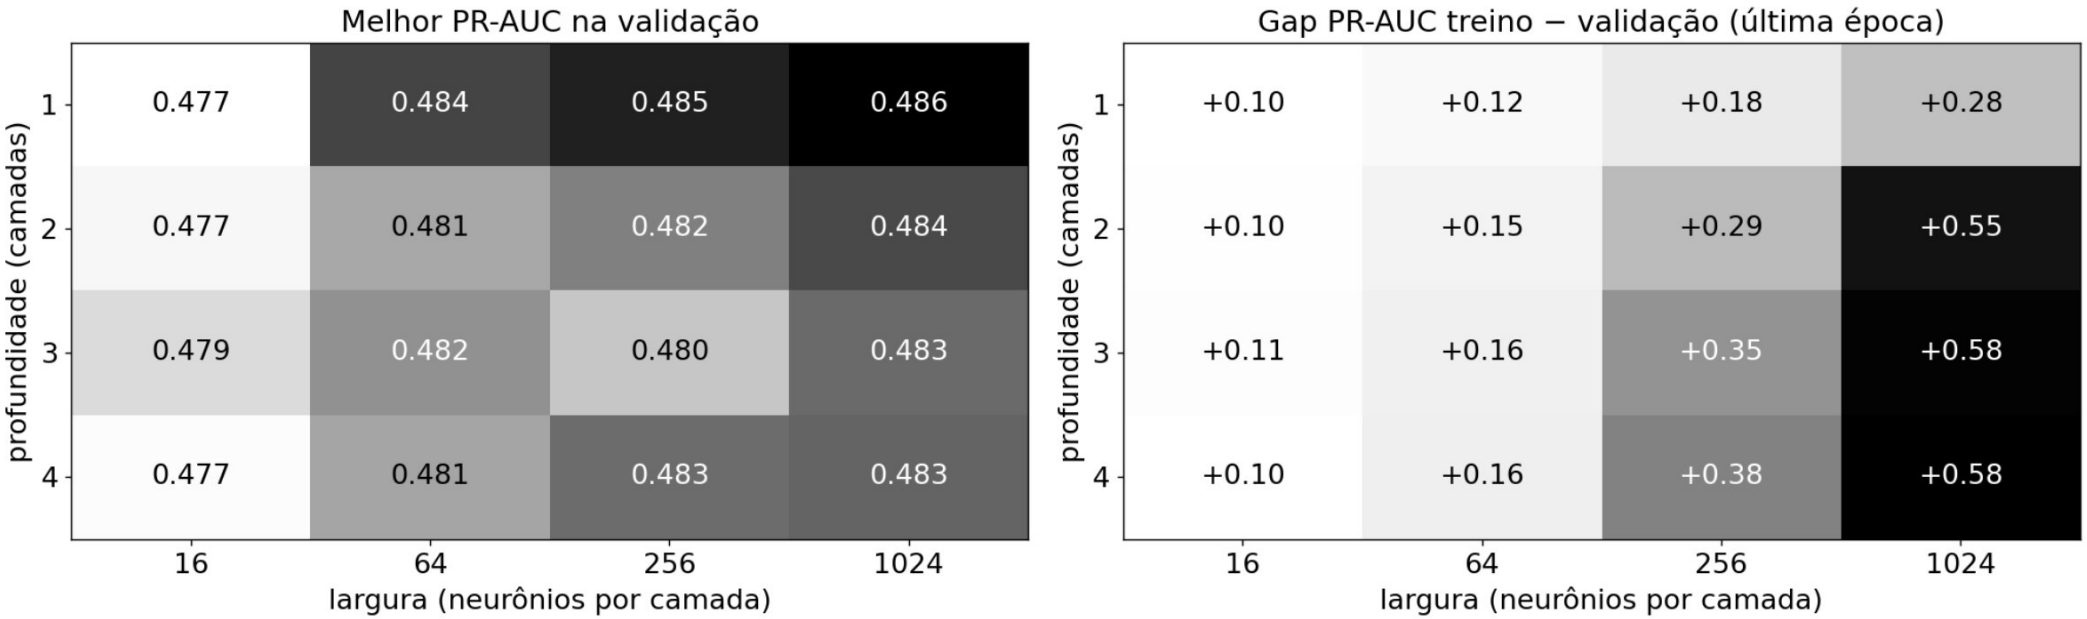
- Campo vazio ou "ignorado" vira uma categoria própria
- Categorias em one-hot: 188 entradas na rede
- Idade e tempos: preencher vazios e padronizar
- Datas impossíveis (ex.: ano 0202) viram vazias
- Tudo calculado só com o treino

O modelo: MLP



- Feita em PyTorch
- Sem camadas ocultas = regressão logística (referência)
- Parada antecipada: para quando a validação não melhora

Experimento 1: tamanho da rede



- Rede maior quase não melhora a validação
- Mas decora o treino: overfitting

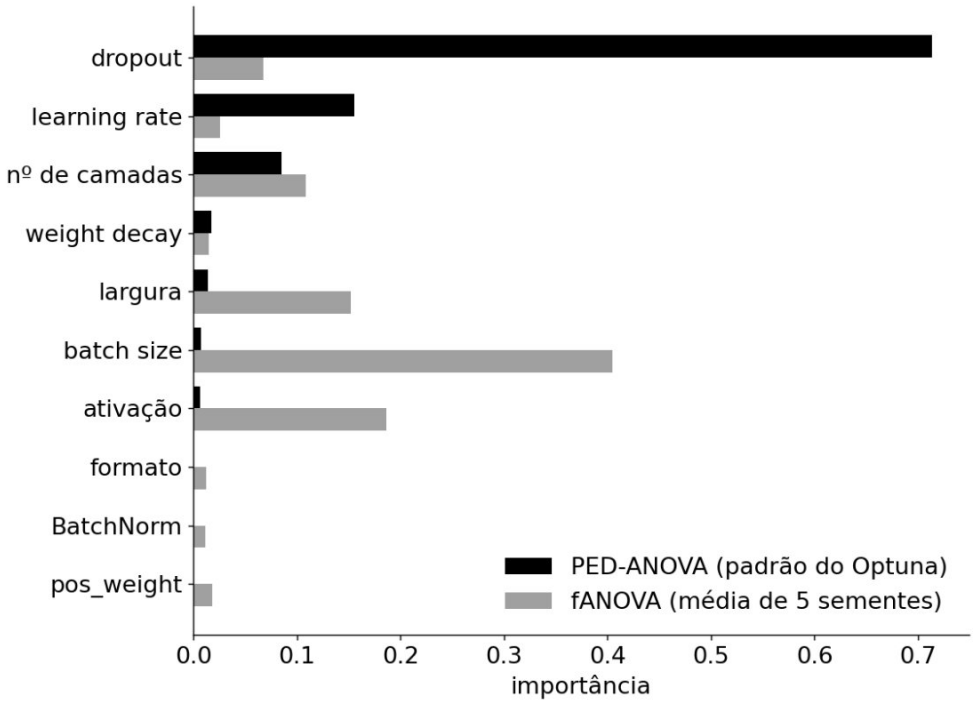
Experimento 2: regularização

Estratégia	PR-AUC final	Tempo
Sem regularização	0,375	21 s
Dropout	0,385	23 s
L2	0,367	25 s
BatchNorm	0,373	26 s
Parada antecipada	0,456	2 s
Dropout + L2 + parada	0,459	4 s

- Parar na hora certa foi o que mais ajudou

Experimento 3: busca com Optuna

- 40 tentativas (23 interrompidas cedo)
- Objetivo: melhor PR-AUC na validação
- Melhor: 5 camadas em funil, GELU, dropout 0,26
- As 10 melhores ficaram parecidas



Comparação dos modelos (teste 2023)

INSTITUTO FEDERAL
Goiás

Modelo	Parâmetros	Tempo de treino	Macro-F1
Regressão logística	189	10 s	0,669
MLP simples (2 × 128)	40 mil	57 s	0,681
MLP do Optuna	271 mil	162 s	0,682
MLP compacta	92 mil	133 s	0,680
MLP grande	271 mil	175 s	0,679

- A MLP é melhor que a regressão logística
- A MLP simples empata com a do Optuna e é 3× mais rápida

Resultado no teste (2023)

Métrica	2022 (val.)	2023 (teste)
Macro-F1	0,687	0,681
ROC-AUC	0,824	0,868
PR-AUC	0,500	0,396
Acerta óbitos	57%	51%
Óbito previsto	33%	21%
Óbito real	18%	10%

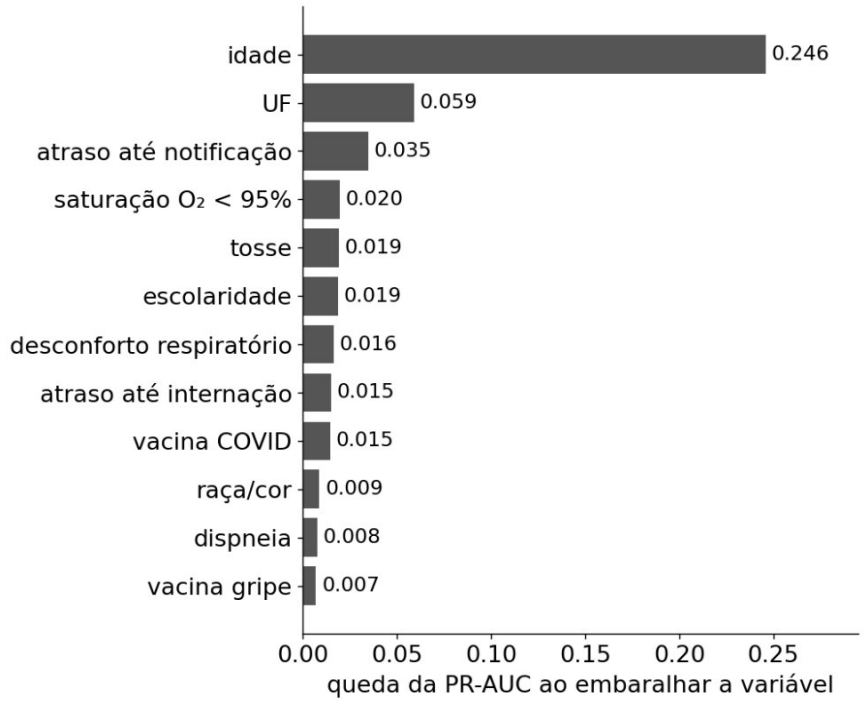
- A Macro-F1 se manteve

- O modelo exagera o risco: prevê 21%, ocorrem 10%

- Ele aprendeu com a época mais grave da COVID

Onde o modelo erra

- A idade é a variável mais importante
- Em crianças, quase nunca prevê óbito (acerta 3%)
- Em idosos, acerta 73% dos óbitos



Limitações

INSTITUTO FEDERAL
Goiás

- A doença e os pacientes mudaram ao longo dos anos
- As probabilidades precisam ser recalibradas
- Muitos campos vazios e erros de digitação
- Só entram casos internados e com desfecho

Conclusões

INSTITUTO FEDERAL
Goiás

- A MLP supera a regressão logística
- Sem regularização há overfitting; parada antecipada resolve
- Uma MLP simples é tão boa quanto a do Optuna
- O modelo se manteve em 2023, mas exagera o risco

INSTITUTO FEDERAL
Goiás

Obrigado!

Dúvidas?

Juliano Costa e Victor Hugo Jesus